# GDNet：从一条流的前五个报文识别安全产品

Luping QAQ，独立研究者


## 摘要

本文提出 GDNet，一个紧凑的字节级分类器，用一条流的前五个报文判断其背后的安全产品。与依赖人工签名表的指纹识别 [17], [19] 以及输出应用类别的学习型流量分类 [8], [9] 不同，GDNet 面向的是终端上的安全产品清单：杀毒、终端检测与响应、VPN、Web 应用防火墙和监控类软件。输入是前五个报文拼成的 1600 字节定长向量，IPv4 地址置零 [1]；编码器为四个 Gated DeltaNet 块，输出 256 维 CLS 特征，四个任务头与一个原型门控共同给出产品标签、类型、层级和显式拒识 [2], [4], [11]。在 503 条流的测试划分上，四臂集成取得 0.8787 的产品准确率、0.9245 的层级准确率和 0.9784 的门控 AUROC，18 个未知产品桶全部被拒识。对六个公开基准的逐字节审计显示，其中五个的训练集与测试集约有 80% 的流完全重复，ISCXTor2016 则为零重复 [14], [15]；因此本文同时报告去重前后的数字，并且不作 SOTA 声明。


关键词：字节级流量分类；安全产品识别；资产发现；无分词器学习；Gated DeltaNet；开集识别；数据集泄漏；加密流量分析

## I 引言

终端上装了什么，通常由资产库回答，而不是由流量回答。资产库在装机时写入，之后很少核对，一台重装过、改过用途或者中途换过 Agent 的主机，其记录与实际安装的产品往往对不上 [14], [16]。这不是某个团队记账不认真：杀毒由运维装，VPN 网关和 WAF 由网络组装，NDR 探针由负责监控的人装，部署工单关闭之后，没有人继续持有这份合并视图 [17], [19], [21]。

按端口和协议划分解决不了这个问题。本文的标签集是封闭的 18 个产品与服务，列在附录 A 并标注类型和层级，其中三个 VPN（wireguard、openvpn、stunnel）都允许自定义端口 [19]，三个 Web 面产品（squid_proxy、ntopng、guacamole_mgmt）默认占用 80 和 443，四个终端 Agent（windows_defender、clamav_freshclam、velociraptor、osquery）的升级流量走的是同一套 HTTPS 形态 [20], [21]。规则型指纹能从报文头特征判断操作系统 [17]、从载荷特征判断协议 [19]、从握手指纹判断 TLS 栈 [18]，学习型设备识别能从流统计判断设备类型 [20], [21]；两者都不输出封闭集里的产品标签，也都不提供在留出会话上标定的拒识选项 [11], [12]。

GDNet 用一个紧凑的字节级模型处理这个设定。输入是前五个报文拼成的 1600 字节，IPv4 地址置零 [1], [7]。编码器是四个 Gated DeltaNet 块，$d_{model} = 256$、$d_{state} = 16$，单臂 2.86M 参数 [2], [3], [4]。分类器是四臂集成，共 11.44M 参数，磁盘占用 46 MB [1], [8], [9]。另有一个独立的原型门控决定产品头是否可信 [11], [12], [13]，系统因此输出产品标签、类型、层级、原型距离和置信度，或者在证据不足时输出 unknown。

设 P 为附录 A 中 18 个产品的封闭集合，T 为产品类型集合，G 为层级集合。对一条流 f，分类器返回五元组 $(\hat{y}, \hat{t}, \hat{g}, d, s)$，其中 $\hat{y}$ 属于 P 或为 unknown，$\hat{t}$ 属于 T，$\hat{g}$ 属于 G，d 为原型距离，s 为置信度 [11], [13]。拒识不是一个额外的输出类别，而是作用在「流嵌入到最近类原型距离」上的阈值 $\tau = 0.1041$，取开发集距离的 68 分位 [12], [13]。训练过程因此不需要任何未知类样本，这一点很重要，因为一个网络里没有安装哪些产品，事先无法枚举 [5], [6]。

在这批 40,283 条标注流上，集成在 503 条流的测试划分上取得 0.8787 的产品准确率、0.9245 的层级准确率和 0.9784 的门控 AUROC，并拒识了接受集里全部 18 个未知产品桶 [14], [16]。采集探针是一个 42 KB 的单文件 C 程序，batch 128 下峰值显存 3.40 GB，单张 RTX 4090 即可跑完整条推理链 [28], [29]。同样的性质也带来敏感性：能枚举一台主机防御栈的人，可以选择绕过它的手法，因此第 VI-E 节专门说明发布约束 [14], [22]。

本文的贡献有四项。

- 提出 GDNet：一个字节级分类器，用前五个报文把流归到 18 个安全产品之一或显式未知类，单臂 2.86M 参数、四臂集成 11.44M 参数，不使用分词器，也不依赖外部预训练语料 [1], [6], [9]。
- 给出一个拒识机制：每类三个原型，阈值在留出会话上标定，在没有未知类样本的情况下拒识了接受集全部 18 个未知桶 [11], [12]。
- 给出六个公开流量基准的逐字节审计：其中五个的训练集与测试集约 80% 完全重复，并量化去重对三个受影响基准的影响 [14], [15], [16]。
- 发布一套带校验和的推理栈，可在不重新分发任何抓包的前提下复现本文数字 [28], [29]。

## II 相关工作

### II-A 流量指纹与资产发现

规则型指纹比本文提到的任何学习型方法都早，而且今天仍在生产网络中运行。p0f 依据初始 TTL、窗口大小、TCP 选项顺序等报文头特征推断操作系统，靠一张人工签名表，不需要训练数据 [17]；nDPI 在链速下匹配载荷与头部模式划分协议 [19]；JA3 与 JA3S 把 TLS ClientHello 和 ServerHello 的字段散列成短字符串，用来识别客户端与服务端实现 [18]。学习型设备识别往前走了一步：IoT Sentinel 用报文头特征训练随机森林，在设备接入前判定设备类型 [21]；Sivanathan 等人在智慧园区与校园网流量上证明，仅凭流统计就能把设备类别分开 [20]。这些工作都停在操作系统、协议或设备类型，没有一个输出本文这样的封闭产品标签集，也没有一个提供拒识选项。

### II-B 字节级流量分类

ET-BERT 先把数据报分词，再用掩码语言建模预训练 Transformer [7]；YaTC 把流画成图像，在图像块上预训练掩码自编码器 [8]；NetMamba 把单向 Mamba 主干用于报文序列 [9]。三者都需要在外部语料上做预训练，也都承袭了文本领域的字节级与子词约定 [5], [6]。MambaNetBurst 去掉了分词器和预训练阶段，用 2.7M 参数的紧凑 Mamba-2 堆栈直接从原始字节学习 [1]，是与本文最接近的架构参照。GDNet 保留它的字节词表、CLS 读出和定长突发约定，把混合器换成四个 Gated DeltaNet 块 [4]，在保持状态空间线性代价 [2], [3] 的同时，把 delta 规则引入状态转移。

### II-C 基础模型与开集识别

netFound 从大规模 token 语料学习报文表示，报告冻结编码器的结果，并明确给出若干数据集的划分修正；其参数量约为单个 2.86M 参数 GDNet 臂的两个数量级 [10]。开集识别把拒识当作独立于分类的决策：softmax 置信度是糟糕的边界估计 [13]，到类原型的距离则是可标定的替代方案 [11], [12]。本文每类保留三个子原型，每条门控臂共 54 行原型，距离定义为一减去最大余弦相似度， τ 只在开发集上标定。

### II-D 数据集泄漏

Trustee 指出网络机器学习系统普遍利用数据集捷径，包括按报文划分和时序相关性 [14]；Pcap-Encoder 证明按报文划分会泄漏 TCP 序列号，模型可以在没学到任务的情况下拿到高分 [15]。netFound 报告了若干公开数据集的修正划分 [10]，NetBench 提出统一评测协议 [16]。第 V-D 节把这条线往前推一步：对 6 个基准、250,072 条流做逐字节重复统计，全程不涉及任何模型。

表 I. GDNet 在指纹识别、学习型分类与基础模型之间的位置。

| 方法 | 表示 | 分词器 | 预训练 | 序列模型 | 目标 |
|---|---|---|---|---|---|
| p0f [17] | TCP/IP 头部字段 | 无 | 无 | 签名表 | 操作系统 |
| nDPI [19] | 载荷 + 头部 | 无 | 无 | DPI 规则 | 协议 |
| JA3/JA3S [18] | TLS 握手字段 | 无 | 无 | 散列 | 客户端/服务端 |
| IoT Sentinel [21] | 头部特征 | 无 | 无 | 随机森林 | 设备类型 |
| ET-BERT [7] | 数据报 token | BERT 词表 | 掩码语言模型 | Transformer | 应用 |
| YaTC [8] | 流图像块 | 图像块 | 掩码自编码 | Transformer | 应用 |
| NetMamba [9] | 报文 token | 词表 | 自监督 | Mamba | 应用 |
| MambaNetBurst [1] | 原始字节 | 无 | 无 | Mamba-2 | 应用 |
| netFound [10] | 报文 token | 词表 | 大规模语料 | Transformer | 多任务 |
| GDNet | 原始字节 | 无 | 域内对比学习 | GDN | 安全产品 |

## III 架构

### III-A 输入表示

一条流被压成 1600 字节的定长向量：五个报文，每个最多 320 字节，其中前 80 字节是头部，后 240 字节是载荷；第 12 到 19 字节存放 IPv4 源目地址，在向量离开探针之前置零，端口、协议号、标志位和载荷内容全部保留 [1], [7]。

$$x = [\, b_1,\ b_2,\ \cdots,\ b_{1600} \,],\ b_i \in \{0,\ \cdots,\ 255\} \qquad (1)$$

不足五个报文的流补零，超过的在同一 1600 字节边界截断；以太网、VLAN 和裸 IPv4 三种封装都接受；解析不在热路径上，因为探针在流的第五个报文到达时就交出了向量 [28]。五个报文的预算覆盖传输层握手和第一条应用消息，附录 A 的 18 个产品都在这一段里露出更新请求、证书或固定头部，而地址属于站点属性、不属于产品属性 [17], [19], [21]。

### III-B 字节嵌入、主干与任务头

每个字节映射为 256 维嵌入，末尾追加一个可学习的 CLS token，加上位置信息后送入四个 GDN 块，最终 CLS 状态作为特征；只在训练期使用的域判别头以 strict=False 加载，推理时丢弃 [1], [4]。四个头合计约 0.4M 参数，占单臂 2.86M 的 14%，其余 86% 都在编码器里。恶意头在公开恶意流量上训练，结果单独报告，因为那个语料的采集条件与任何一个具体站点都不一致。

表 II. 单臂主干配置。

| 组件 | 取值 |
|---|---|
| 字节嵌入 | 256 |
| GDN 块 | 4 个，$d_{model} = 256$，$d_{state} = 16$ |
| CLS token | 可学习，追加在最后一个字节之后 |
| 特征 | 最终 CLS 状态，256 维 |
| 状态字典条目 | 103 条，其中 52 条属于 GDN 块 |
| 单臂参数量 | 2.86M |

表 III. 四个任务头，合计约 0.4M 参数。

| 任务头 | 层结构 | 输出维度 | 是否进入主结果 |
|---|---|---|---|
| 产品 | 256-512-18 | 18 | 是 |
| 层级 | 256-3 线性 | 3 | 是 |
| 类型 | 256-512-10 | 10 | 是 |
| 恶意 | 256-512-11 | 11 | 单独报告 |

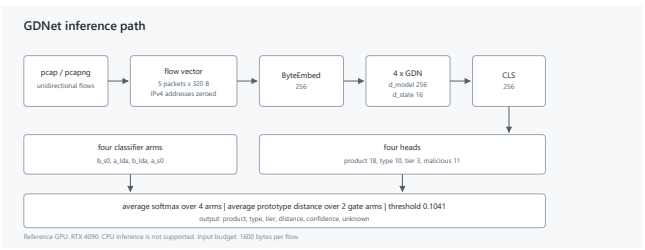



图 1. 单臂推理路径。

### III-C 开集判定

每类用 KMeans 在训练嵌入上生成三个原型，每条门控臂共 54 行原型。对于特征 f 与类 c 的原型集 $P_c$，距离与判定规则为

$$d(f) = 1 - \max_{c,\,k} \cos(\, f,\ p_{c,k} \,),\ p_{c,k} \in P_c \qquad (2)$$

$$\hat{y} = \operatorname{argmax}_c\ s_c(f) \ \text{ if } \bar{d}(f) \leqslant \tau,\ \text{otherwise unknown} \qquad (3)$$

其中 s 是平均后的 softmax 向量，$\bar{d}$ 是两条门控臂上的平均距离， τ = 0.1041 取开发集距离的 68 分位 [11], [12], [13]。余弦距离落在 [0, 2] 区间内，阈值因此是开发分布上的分位数而不是绝对相似度，换一个站点必须重新标定，因为阈值属于流量而不属于模型。

### III-D 集成、复杂度与占用

共训练六个臂：两个预训练轮次（A、B）与三种训练变体交叉，变体分别是标准多任务目标（S0）、按类先验做 logit 调整（LDA）、在对比项中加权难负样本（HN）。保留四个：A-S0、A-LDA、B-LDA、B-S0；A-HN 与 B-HN 的 AUROC 更高，但阈值一动门控距离就漂移，因此按稳定性而非准确率剔除 [1], [9]。平均不加权。

表 IV. 六个训练臂。发布的检查点使用同一标签的小写形式，例如 A-S0 对应 `stage3_a_s0.pth`。

| 臂 | 预训练轮次 | 训练变体 | 在发布中的角色 |
|---|---|---|---|
| A-S0 | A | 标准多任务 | 分类臂 |
| A-LDA | A | logit 调整 | 分类臂与门控臂 |
| B-LDA | B | logit 调整 | 分类臂与门控臂 |
| B-S0 | B | 标准多任务 | 分类臂 |
| A-HN | A | 难负样本加权 | 已剔除 |
| B-HN | B | 难负样本加权 | 已剔除 |

$$s(f) = (1/4)\ \Sigma_{j=1..4}\ \mathrm{softmax}(\ z_j(f)\ ),\ \bar{d}(f) = (1/2)\ \Sigma_{j\ \in\ \{A\text{-}LDA,\ B\text{-}LDA\}}\ d_j(f) \qquad (4)$$

Gated DeltaNet 块对序列长度是线性的，单次前向代价为 $O(L \cdot d_{model} \cdot d_{state})$，$L = 1{,}600$ [2], [3], [4]；显存由激活而非权重主导，46 MB 参数对应 batch 128 下 3.40 GB 峰值显存。

```
算法 1：单条流的推理
输入：报文流，阈值 τ
      臂集合 S = {A-S0, A-LDA, B-LDA, B-S0}
输出：产品、类型、层级、距离、置信度，或 unknown

采集一条单向流的前五个报文
x <- 1600 字节向量，第 12:20 字节置零
对 S 中每个臂 j：
    e_j <- GDN_encoder_j(x)                  # 256 维 CLS
    s_j <- softmax(product_head_j(e_j))      # 18 个 logit
s <- 各臂 s_j 的均值
d <- 两条门控臂上 1 - max cosine(e, prototype) 的均值
若 d <= τ：返回 argmax s、类型头、层级头、d、max s
否则：     返回 unknown、d
```

## IV 实验

### IV-A 数据、划分与实现

标注集包含 18 个类别的 40,283 条流，采集自实验主机与虚拟机，每个产品都按其正常的升级、遥测或管理路径施放流量，而不是用合成载荷 [7], [8], [30], [32]。划分发生在流级别而不是会话级别；每类恰好出现在一个留出会话中，因此测试数字描述的是那些会话，而不是一个新组织；14 个会话覆盖 18 个类别，是因为一次采集会话会在一台主机上同时跑多个产品 [14], [16]。

表 V. 数据、划分与训练配置。

| 项目 | 取值 |
|---|---|
| 类别 | 18 个产品与服务 |
| 标注流数 | 40,283 |
| 采集来源 | 实验主机与虚拟机 |
| 验证流数 | 1,006，来自 14 个留出会话 |
| 开发/测试划分 | 503 / 503，流级别 |
| 选择方式 | 阈值、检查点与集成只在开发集上确定 |
| 测试使用次数 | 一次 |
| 硬件 | 4 × RTX 4090，fp32 |
| 第一阶段 | 对比学习，NT-Xent，33,184 条仅训练流 |
| 第二阶段 | 多任务监督微调，60 轮 |
| 第三阶段 | REINFORCE，300 轮 |
| 参考环境 | Python 3.12，PyTorch 2.14 |

训练代码不在发布包内，因为它依赖实验数据的目录结构，换一个团队使用前需要清理；而发布的检查点、54 行原型、0.1041 阈值和评测脚本可以直接复现测试划分上的数字 [28], [29]。模型选择全部限制在 503 条流的开发半区，503 条流的测试半区只打分一次 [14], [16]。

训练分三段。第一段在 33,184 条仅训练流上优化 NT-Xent 对比目标 [23]；第二段加入域对抗项 [24]，优化器为 AdamW [26]，其默认超参沿自 Adam [27]；第三段用 REINFORCE 优化产品正确、类型正确与诚实拒识三项奖励 [25]。

可复现性分两半。发布的检查点、54 行原型、阈值和评测脚本，在评测划分可得的前提下能复现测试半区的数字；划分本身不分发，只因为它来自实验流量。探针到服务的链路在测试主机上 30 秒采集 99,888 条流，服务把容器管理类流量判为 unknown，这正是产品域之外的预期行为。

### IV-B 指标

产品准确率统计完全正确的产品标签，层级准确率统计完全正确的层级标签。宏 F1 在至少有一条测试流的类别上取平均：

$$F1_{macro} = (1/|C^+|)\ \Sigma_{c\ \in\ C^+}\ 2\ P_c\ R_c\ /\ (P_c + R_c) \qquad (5)$$

其中 $C^+$ 就是该类别集合。门控 AUROC 把已知流与未知、新颖流放在一起比较 [12], [13]；未知拒识率统计被正确拒绝的未知产品桶占比；恶意宏 F1 在去重后的 USTC-TFC2016 测试集（1,242 条流）上计算 [15], [32]；准确率区间为 95% 置信度的 Wilson 区间。

## V 结果

表 VI. 封闭集准确率、门控质量与拒识。

| 指标 | 测试（503 条流） | Wilson ± | 全验证集（1006 条流） | Wilson ± |
|---|---|---|---|---|
| 产品准确率 | 0.8787 | 0.029 | 0.8817 | 0.020 |
| 层级准确率 | 0.9245 | 0.023 | 0.9334 | 0.016 |
| 宏 F1（有支撑类别） | 0.7621 | — | 0.8240 | — |
| 门控 AUROC | 0.9784 | — | 0.9820（开发集） | — |
| 未知拒识 | 18/18 | — | 18/18 | — |
| 恶意宏 F1（去重 USTC） | — | — | 0.9702 | — |
| 恶意二分类 F1 | — | — | >0.994 | — |

### V-A 安全产品识别

产品头在测试半区取得 0.8787，在全验证集取得 0.8817；层级准确率分别为 0.9245 和 0.9334，门控 AUROC 为 0.9784 和 0.9820 [1], [9]。18 个未知产品桶在固定阈值 0.1041 下全部被拒识，且拒识率在 $q = 0.64$ 到 $q = 0.75$ 之间保持不变 [11], [12]；wireguard 只有一条测试流，一次错误就让该类在 1.0 和 0.0 之间跳动，因此测试半区的宏 F1 0.7621 不作为主指标 [14], [16]。全验证集的 0.8240 是更稳定的参照，恶意头在 1,242 条去重 USTC 流上取得 0.9702 宏 F1，二分类 F1 不低于 0.994 [15], [32]。

### V-B 接受集与注册

表 VII. 264 个产品桶与 18 个未知桶上的接受与注册表现。

| 项目 | 结果 |
|---|---|
| 产品桶 | 264 |
| 未知桶 | 18，全部拒识 |
| 原始集成判对的产品数 | 8/10 |
| 加入时间规则后判对的产品数 | 9/10，规则未发布 |
| stunnel 召回 | 所有阈值下 0/30 |
| wireguard | 2 个桶，视为噪声 |
| HTTP 服务，FLW1 记录 | 6/6 |
| smb 注册 | 注册三个子原型后 8/8 |

基于到达间隔的时间规则把接受数从 8 提到 9，但没有随版本发布，因为它是一个没有独立标定的第二模型；stunnel 是修不动的失败项，在试过的每个阈值上都是 30 个桶零命中；smb 在注册三个子原型后达到 8/8，说明机制本身可用，但补不上 stunnel 缺的数据。HTTP 服务在 FLW1 记录上返回 6/6 已知流，这是全文唯一一条走完整部署代码路径的端到端检查 [28], [29]。

### V-C 吞吐与显存

表 VIII. 单张 RTX 4090、fp32 下的吞吐与显存，显存按 batch 128 测，延迟按 batch 1 测。

| 配置 | 吞吐 | batch 1 延迟 | batch 128 峰值显存 |
|---|---|---|---|
| 单臂 | 1,017 条流/秒 | 10.7 ms | 3.37 GB |
| 四臂集成 | 253 条流/秒 | 43.1 ms | 3.40 GB |
| 蒸馏学生 | 1,011 条流/秒 | 10.6 ms | 3.37 GB |

探针的采集速度高于集成 253 条流/秒的分类速度，因此部署上只有三条路：抽样、分片到多卡，或者按需分类；8 GB 卡在 batch 128 下仍有富余，峰值显存 3.40 GB [28], [29]。蒸馏学生达到 1,011 条流/秒、0.8231 的验证准确率，比集成低 5.6 个点，因此保持实验状态 [23]。

### V-D 公开划分审计

表 IX. 六个公开基准的逐字节训练/测试重叠。

| 基准 | 训练 | 测试 | 训练 ∩ 测试 | 占测试比例 | 干净测试集 |
|---|---|---|---|---|---|
| ISCXVPN2016 | 13,281 | 1,384 | 1,106 | 79.9% | 278 |
| ISCXTor2016 | 11,655 | 1,458 | 0 | 0% | 1,458 |
| USTC-TFC2016 | 37,323 | 6,662 | 5,605 | 84.1% | 1,057 |
| CICIoT2022 | 18,734 | 1,951 | 1,571 | 80.5% | 380 |
| CrossPlatform-Android | 44,700 | 4,656 | 3,733 | 80.2% | 923 |
| CrossPlatform-iOS | 40,379 | 4,205 | 3,396 | 80.8% | 809 |

审计对每条流做两次散列：一次对 PNG 文件字节，一次对解码后的灰度像素；250,072 条流上两者完全一致，因此可以排除 PNG 编码或元数据造成重叠的可能；重复的定义是逐字节完全相同，单位是 1600 字节，也就是模型消费的同一个向量 [14], [15]。重复比例分别是 ISCXVPN2016 的 79.9%、USTC-TFC2016 的 84.1%、CICIoT2022 的 80.5%、CrossPlatform-Android 的 80.2%、CrossPlatform-iOS 的 80.8%，对应的干净测试集为 278、1,057、380、923 和 809 条流；ISCXTor2016 的 1,458 条测试流一条也不重复 [30], [31], [32]。

跨划分的标签冲突为零，所有重复都落在同一个类内，这与「从同一个流池独立抽样、划分之间没有去重」相符 [14], [16]。这个结论并非普遍成立：Lens 官方划分在四个在研任务上的突发重叠在 7.0% 到 17.2% 之间，在两个移动任务上只有 0.05% 到 0.5%，与测试集的冲突行最多 57 条 [10], [16]。

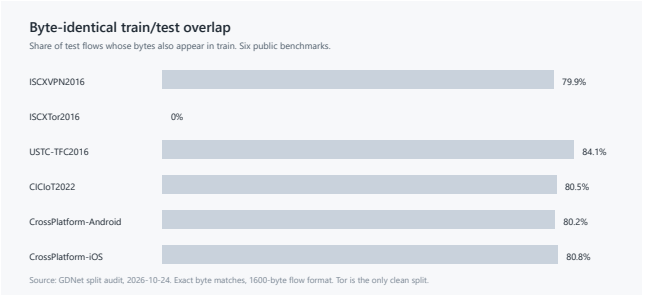



图 2. 六个审计基准的逐字节训练/测试重叠。

### V-E 去重后评估

表 X. 三个受影响基准在去重子集上的重评。

| 项目 | VPN | USTC | CIoT |
|---|---|---|---|
| 干净测试流数 | 278 | 1,057 | 380 |
| 干净集准确率 | 0.9376 | 0.9981 | 0.9868 |
| 干净集宏 F1 | 0.9418 | 0.9671 | 0.9823 |
| 全集宏 F1 | 0.9861 | 0.9949 | 0.9965 |
| 下降 | −4.4 pp | −2.8 pp | −1.4 pp |

在干净子集上重打分，VPN 的宏 F1 掉 4.4 个百分点，USTC 掉 2.8，CIoT 掉 1.4，说明泄漏抬高了分数但没有解释全部；这三个基准的两个数字都在此报告，没有重跑的三个都不报告 [15], [16]。ISCXTor2016 无需重跑；内部报告在同一批干净子集上重打了外部基线，这个对比不放进本文，因为它依赖的检查点不由本文分发 [10]。

### V-F 消融与未发布的变体

表 XI. 尝试过的变体与消融。

| 变体 | 结果 | 处置 |
|---|---|---|
| 辅助预训练（字段、顺序、重建） | 探针 +9.35 点；下游 E1 低于 E0+LDA | 未采用 |
| 时间规则 | 接受数 8 提到 9；邻近阈值不稳定 | 未发布 |
| 蒸馏 | 验证准确率 0.8231，比集成低 5.6 点 | 实验状态 |
| stunnel 阈值调参 | 所有阈值下 0/30 | 需要数据或注册 |
| 两个难负样本臂 | AUROC 更高，门控距离随 τ 漂移 | 剔除 |

辅助预训练原本是最被看好的一项：加入字段、顺序、重建三个目标后，探针分数提高 9.35 点，随后在下游输给朴素的 E0+LDA 流水线，说明代理指标变好不等于模型变好 [6], [23]。消融范围很窄，这一点明确写出：深度、宽度、状态维度、嵌入维度和报文预算都是按部署约束和 MambaNetBurst 参照一次性确定的，没有做扫描，算力投在了 250,072 条流的审计和 264 个桶的接受集上 [1], [3]。

## VI 讨论

### VI-A 五个报文够用，因为握手就是产品自报家门的地方

附录 A 里 18 个产品各自会在前五个报文内露出更新请求、证书、固定头部或版本串 [17], [19], [21]，接受集仅凭这个预算就判对 8/10；第六个报文之后承载的是用户的载荷，属于用户而不属于产品。

### VI-B 模型大小由部署约束决定

单臂 2.86M 参数、集成 11.44M 参数，折算 46 MB 磁盘占用、batch 128 下 3.40 GB 峰值显存，42 KB 的探针可以跑在没有 Python 运行时的容器里 [28], [29]；更大的模型大概率分数更高 [1], [10]，但这里的运行约束是那张同时跑分析师工具的 8 GB 卡。

### VI-C 拒识比准确率更重要

门控在 $\tau = 0.1041$ 下拒识 18/18 个未知桶，且工作点在 $q = 0.64$ 到 $q = 0.75$ 之间稳定 [11], [12]；没有这层拒识，0.8787 的产品准确率会在遇到 18 类之外的流时把响应者引向一台根本没装那个软件的主机 [13], [22]。

### VI-D 有效性威胁

划分是流级别、每类只有一个会话，绝对数字描述的是那 14 个会话 [14], [16]；503 条流的测试集在产品准确率上给出 ±0.029 的 Wilson 区间，宏 F1 在没有逐类计数的前提下给不出区间；只用了单一采集环境，跨站点行为未测；审计只做精确重复，覆盖不到近似重复、跨数据集重叠和划分内部的标签错误 [14], [15]；标签集封闭在 18 个产品，静默升级、不产生特征流量的产品会被拒识或误判；没有做种子扫描。

### VI-E 用途与滥用

发布包含 19 个权重文件、合计 94.6 MB、无抓包、带 SHA-256 校验和；工具会点名防御产品，因此只在有授权的环境运行，抓包不进入公开演示 [22]。输出是分数而不是判决，恶意头单独报告并排除在自动响应路径之外，输入不含地址，除字节模式外也不含载荷语义。

## VII 结论

本文系统在 503 条流的测试划分上取得 0.8787 的产品准确率、0.9245 的层级准确率和 0.9784 的门控 AUROC，接受集 18 个未知产品桶全部拒识；模型 11.44M 参数，不使用分词器，流与训练集不相似时输出 unknown [1], [9]。审计部分的结论更值得记住：六个公开基准里有五个存在约 80% 的训练与测试重叠，合计 250,072 条受审流 [14], [15], [16]。

## 致谢

感谢 flash-linear-attention 提供 Gated DeltaNet 内核 [29]，也感谢公开基准的作者把数据集开放到可以独立核验的程度 [30], [31], [32]。

## 参考文献

[1] G K Kulatilleke, S Layeghy, M Baktashmotlagh, M Portmann, "MambaNetBurst: direct byte-level network traffic classification without tokenization or pretraining," arXiv:260511034, 2026；[2] A Gu, T Dao, "Mamba: linear-time sequence modeling with selective state spaces," arXiv:231200752, 2023；[3] T Dao, A Gu, "Transformers are SSMs: generalized models and efficient algorithms through structured state space duality," Proc ICML, 2024；[4] S Yang, J Kautz, A Hatamizadeh, "Gated delta networks: improving Mamba2 with the delta rule," Proc ICLR, 2025；[5] A Vaswani et al, "Attention is all you need," Proc NeurIPS, 2017；[6] L Xue et al, "ByT5: towards a token-free future with pre-trained byte-to-byte models," TACL, vol 10, 2022；[7] X Lin, G Xiong, G Gou, Z Li, J Shi, J Yu, "ET-BERT: a contextualized datagram representation with pre-training transformers for encrypted traffic classification," Proc WWW, 2022；[8] R Zhao, M Zhan, X Deng, Y Wang, Y Wang, G Gui, Z Xue, "YaTC: a masked autoencoder for flow images," arXiv:230519077, 2023；[9] NetMamba: efficient traffic classification with a pre-trained unidirectional Mamba, arXiv:240511886, 2024；[10] netFound: a foundation model for network security, arXiv:231017025, 2023; revised 2026；[11] J Snell, K Swersky, R Zemel, "Prototypical networks for few-shot learning," Proc NeurIPS, 2017；[12] W J Scheirer, A de Rezende Rocha, A Sapkota, T E Boult, "Toward open set recognition," IEEE TPAMI, vol 35, no 7, 2013；[13] A Bendale, T E Boult, "Towards open set deep networks," Proc IEEE CVPR, 2016；[14] N Jacobs et al, "AI/ML for network security: the emperor has no clothes," Proc ACM CCS, 2022；[15] R Zhao et al, "The sweet danger of sugar: the pitfalls of pcap-based encoders," Proc ACM SIGCOMM, 2025, arXiv:250716438；[16] NetBench: a benchmark for network traffic classification, Proc ACM FMSys, 2024；[17] M Zalewski, "p0f v3," https://lcamtufcoredumpcx/p0f3/；[18] J Althouse, "TLS fingerprinting with JA3 and JA3S," Salesforce Engineering, 2017；[19] L Deri, M Martinelli, T Bujlow, A Cardigliano, "nDPI: open-source high-speed deep packet inspection," Proc IEEE IWCMC, 2014；[20] A Sivanathan, H H Gharakheili, F Loi, A Radford, C Wijenayake, A Vishwanath, V Sivaraman, "Characterizing and classifying IoT traffic in smart cities and campuses," Proc IEEE INFOCOM Workshops, 2017；[21] M Miettinen, S Marchal, I Hafeez, N Asokan, A-R Sadeghi, S Tarkoma, "IoT Sentinel: automated device-type identification for security enforcement in IoT," Proc IEEE ICDCS, 2017；[22] R Sommer, V Paxson, "Outside the closed world: on using machine learning for network intrusion detection," Proc IEEE S&P, 2010；[23] T Chen, S Kornblith, M Norouzi, G Hinton, "A simple framework for contrastive learning of visual representations," Proc ICML, 2020；[24] Y Ganin et al, "Domain-adversarial training of neural networks," JMLR, vol 17, no 59, 2016；[25] R J Williams, "Simple statistical gradient-following algorithms for connectionist reinforcement learning," Machine Learning, vol 8, 1992；[26] I Loshchilov, F Hutter, "Decoupled weight decay regularization," Proc ICLR, 2019；[27] D P Kingma, J Ba, "Adam: a method for stochastic optimization," Proc ICLR, 2015；[28] A Paszke et al, "PyTorch: an imperative style, high-performance deep learning library," Proc NeurIPS, 2019；[29] flash-linear-attention, https://githubcom/fla-org/flash-linear-attention；[30] G Draper-Gil, A H Lashkari, M S I Mamun, A A Ghorbani, "Characterization of encrypted and VPN traffic using time-related features," Proc ICISSP, 2016；[31] A H Lashkari, G Draper-Gil, M S I Mamun, A A Ghorbani, "Characterization of Tor traffic using time-based features," Proc ICISSP, 2017；[32] W Wang, M Zhu, J Wang, X Zeng, Z Yang, "End-to-end encrypted traffic

classification with one-dimensional convolution neural networks,″ Proc IEEE ISI, 2017。

## 附录 A 标签集

表 XII. 作为封闭标签集的 18 个产品与服务，含类型与层级。

| 产品 | 类型 | 层级 |
|---|---|---|
| windows_defender | 杀毒 | 安全软件 |
| clamav_freshclam_win | 杀毒 | 安全软件 |
| clamav_freshclam | 杀毒 | 安全软件 |
| velociraptor | EDR / HIDS | 安全软件 |
| velociraptor_win | EDR / HIDS | 安全软件 |
| osquery | EDR / HIDS | 安全软件 |
| wazuh_agent | EDR / HIDS | 安全软件 |
| wireguard | 零信任 / VPN | 安全设备 |
| openvpn | 零信任 / VPN | 安全设备 |
| stunnel | 零信任 / VPN | 安全设备 |
| squid_proxy | 上网行为管理 | 安全设备 |
| ntopng | NDR | 安全设备 |
| guacamole_mgmt | 堡垒机 | 安全设备 |
| waf_modsecurity | WAF | 安全设备 |
| suricata_update | NDR | 安全设备 |
| web_http | 浏览器 | 生产软件 |
| ssh | 远程管理 | 生产软件 |
| ftp | 文件传输 | 生产软件 |

发布内容中没有任何抓包：权重在实验流量和公开基准的训练划分上训练，校验和让任何读者都能核对实际加载的是哪些文件[29]。